# Темпоральные GNN и задача ЕТА

Зелинский Никита

### План лекции

O1. Graph attention

### План лекции

O1. Graph attention

O2. Темпоральные GNN

### План лекции

O1. Graph attention

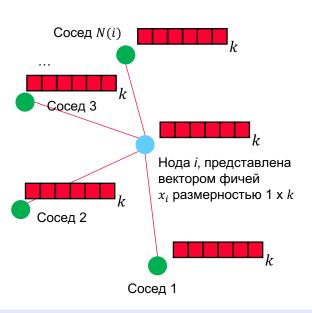
O2. Темпоральные GNN

**ОЗ.** Задача ETA



## Графовая свертка GraphConv





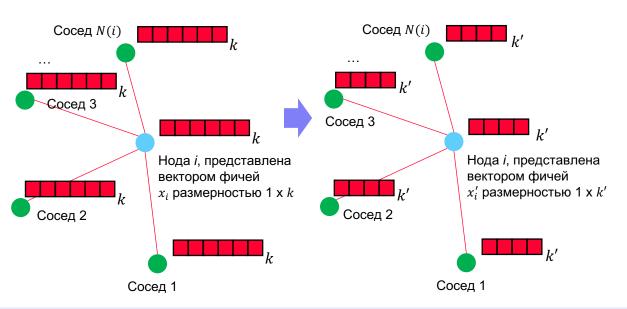
https://pytorchgeometric.readthedocs.io/en/latest/generated/torch\_geometric.nn.conv.GraphConv.html

## Графовая свертка GraphConv



$$x_i' = Hx_i + \sum_{j \in [1, N(i)]} Wx_j$$

W и H имеют размерность k x k': (1 x k) \* (k x k') = 1 x k'



https://pytorch-

geometric.readthedocs.io/en/latest/generated/torch\_geometric.nn.conv.GraphConv.html

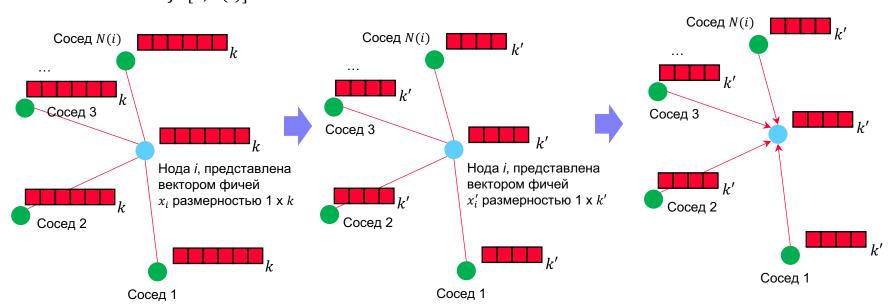
#### ' ' C

## Графовая свертка GraphConv



$$x_i' = Hx_i + \sum_{j \in [1, N(i)]} Wx_j$$

$$W$$
 и  $H$  имеют размерность  $k \ x \ k'$ :  $(1 \ x \ k) \ ^* (k \ x \ k') = 1 \ x \ k'$ 



https://pytorch-

geometric.readthedocs.io/en/latest/generated/torch\_geometric.nn.conv.GraphConv.html

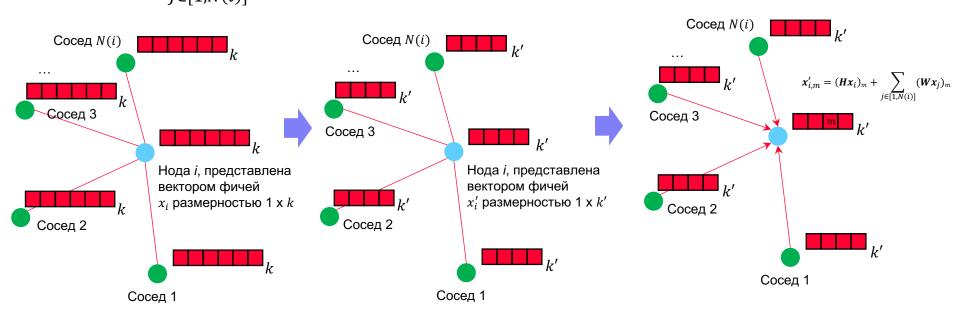
## M T

## Графовая свертка GraphConv



$$x_i' = Hx_i + \sum_{j \in [1, N(i)]} Wx_j$$

W и H имеют размерность k x k': (1 x k) \* (k x k') = 1 x k'

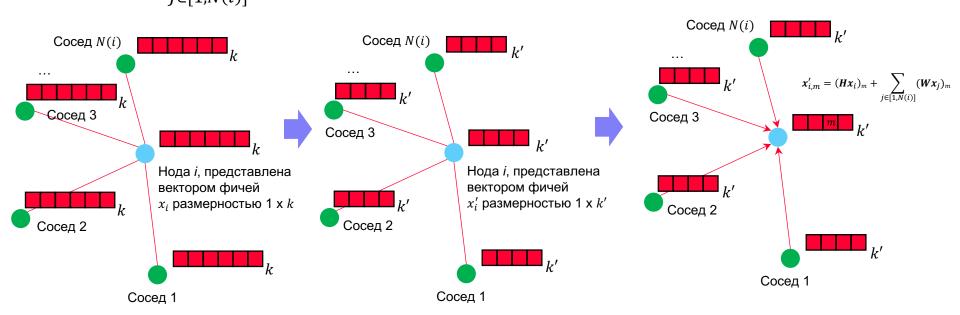


https://pytorch-

geometric.readthedocs.io/en/latest/generated/torch\_geometric.nn.conv.GraphConv.html

## Графовая свертка GraphConv





https://pytorch-

geometric.readthedocs.io/en/latest/generated/torch\_geometric.nn.conv.GraphConv.html

Вместо суммы – другие агрегирующие функции



GraphConv

$$x_i' = Hx_i + \sum_{j \in [1,N(i)]} Wx_j$$

$$X' = \sigma \big(\widetilde{D}^{-1/2} \widetilde{A} \widetilde{D}^{-1/2} XW\big)$$



GraphConv

$$x_i' = Hx_i + \sum_{j \in [1,N(i)]} Wx_j$$

$$X' = \sigma \big(\widetilde{D}^{-1/2} \widetilde{A} \widetilde{D}^{-1/2} XW\big)$$

Чем отличаются 
$$A$$
 и  $\widetilde{A}$  ?

$$\tilde{A} = A + I_N$$



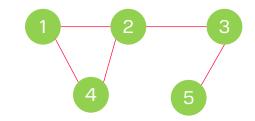
GraphConv

$$x_i' = Hx_i + \sum_{j \in [1,N(i)]} Wx_j$$

Чем отличаются A и  $\widetilde{A}$  ?

$$X' = \sigma \left( \widetilde{D}^{-1/2} \widetilde{A} \widetilde{D}^{-1/2} XW \right)$$

$$\tilde{A} = A + I_N$$



0	1					1	1			
1	0					1	1			
		0		1	$\longrightarrow$			1		1
	1		0				1		1	
		1		0				1		1

М Т С

GraphConv

$$x_i' = Hx_i + \sum_{j \in [1,N(i)]} Wx_j$$

GCNConv

$$X' = \sigma \big(\widetilde{D}^{-1/2} \widetilde{A} \widetilde{D}^{-1/2} XW\big)$$

Чем отличаются A и  $\widetilde{A}$  ?

$$\tilde{A} = A + I_N$$

$$\widetilde{D}_{ii} = \sum_{j} \widetilde{A}_{ij}$$

GraphConv

$$x_i' = Hx_i + \sum_{j \in [1,N(i)]} Wx_j$$

$$X' = \sigma \left( \widetilde{D}^{-1/2} \widetilde{A} \widetilde{D}^{-1/2} XW \right)$$

Чем отличаются 
$$A$$
 и  $\widetilde{A}$  ?

$$\tilde{A} = A + I_N$$

$$\widetilde{D}_{ii} = \sum_{j} \widetilde{A}_{ij}$$

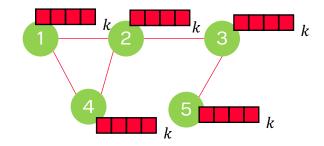
Еще пишут так 
$$\tilde{X} = GCN(A, X) = ReLU(\tilde{A}XW_0)$$

$$\tilde{A} = \tilde{D}^{-1/2} \hat{A} \tilde{D}^{-1/2}$$
  $\tilde{A} = A + I_N$ 

$$\hat{A} = A + I_N$$

### м т С

### Графовая свертка GCNConv

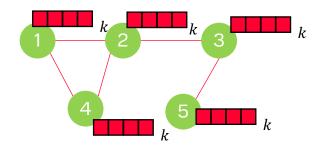


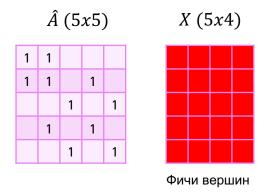
 $\hat{A}$  (5x5)

1	1			
1	1		1	
		1		1
	1		1	
		1		1

### м т С

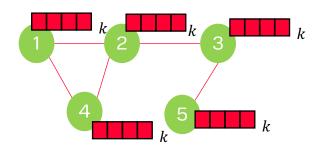
## Графовая свертка GCNConv



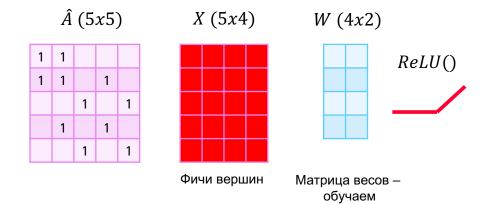


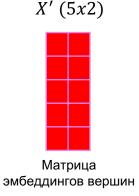
# **Л** Т

### Графовая свертка GCNConv



$$X' = \sigma \big(\widetilde{D}^{-1/2} \widetilde{A} \widetilde{D}^{-1/2} XW\big)$$





### Отличаются?

GraphConv

$$x_i' = Hx_i + \sum_{j \in [1,N(i)]} Wx_j$$

**GCNConv** 

$$X' = \sigma(\widetilde{D}^{-1/2}\widetilde{A}\widetilde{D}^{-1/2}XW)$$

HO!

### Отличаются?

М Т С

GraphConv

$$x_i' = Hx_i + \sum_{j \in [1,N(i)]} Wx_j$$

**GCNConv** 

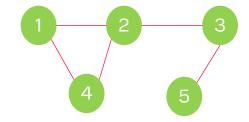
$$X' = \sigma(\widetilde{D}^{-1/2}\widetilde{A}\widetilde{D}^{-1/2}XW)$$

HO!

Работает для бипартитных графов!

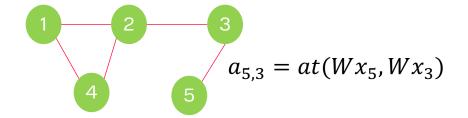
## Идея Graph Attention (не механизм)





### м т С

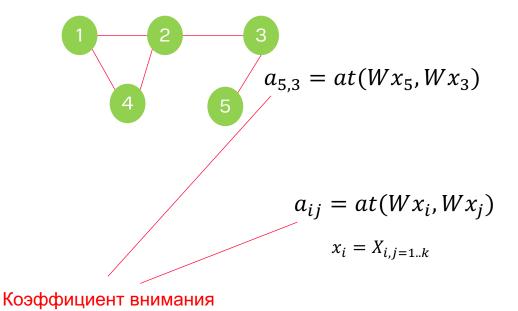
### Идея Graph Attention (не механизм)



$$a_{ij} = at(Wx_i, Wx_j)$$
$$x_i = X_{i,j=1..k}$$

### м т С

### Идея Graph Attention (не механизм)



#### l T C

$$a_{ij} = at(Wx_i, Wx_j)$$

1. Давайте считать  $a_{ij}$  только для вершин, имеющих общее ребро (показано на экспериментах что хватает 1 шага) – назовем это **masked attention** 

$$a_{ij} = at(Wx_i, Wx_j)$$

- 1. Давайте считать  $a_{ij}$  только для вершин, имеющих общее ребро (показано на экспериментах что хватает 1 шага) назовем это **masked attention**
- 2. Давайте нормировать коэффициенты внимания

$$\alpha_{ij} = softmax_j (a_{ij}) = \frac{e^{a_{ij}}}{\sum_{k \in N_i} e^{a_{ik}}}$$

### **Graph Attention**

$$a_{ij} = at(Wx_i, Wx_j)$$

- 1. Давайте считать  $a_{ij}$  только для вершин, имеющих общее ребро (показано на экспериментах что хватает 1 шага) назовем это **masked attention**
- 2. Давайте нормировать коэффициенты внимания

$$\alpha_{ij} = softmax_j (a_{ij}) = \frac{e^{a_{ij}}}{\sum_{k \in N_i} e^{a_{ik}}}$$

3. Давайте внимание сделаем линейным слоем с функцией активации LeakyReLU

$$\alpha_{ij} = \frac{e^{LeakyReLU(a^T[Wx_i||Wx_j])}}{\sum_{k \in N_i} e^{LeakyReLU(a^T[Wx_i||Wx_k])}}$$

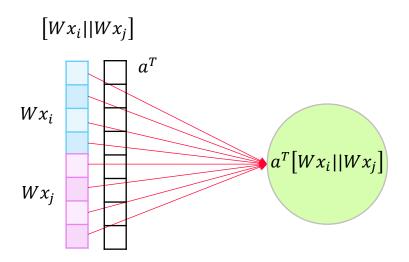
### м т С

### **Graph Attention**

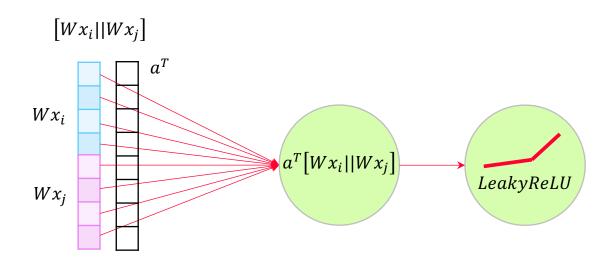
 $\left[Wx_i||Wx_j\right]$ 

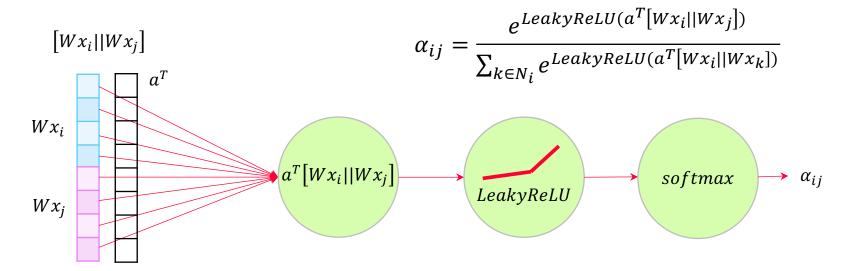


# **Л** Т



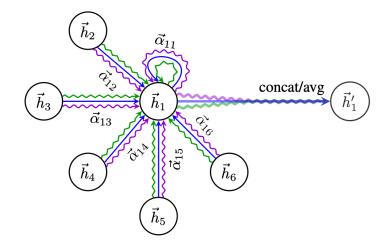
# **Л** Т



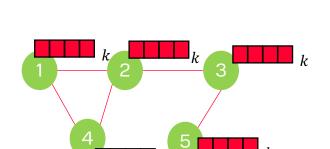


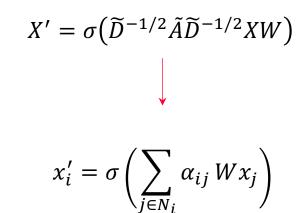
#### I T C

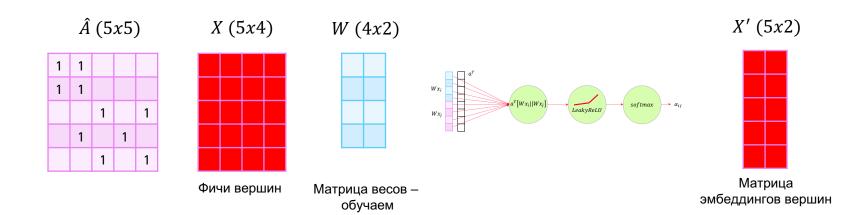
### **Multihead Graph Attention**



### Графовая свертка GATConv







### Реализация в РуG



The graph attentional operator from the "Graph Attention Networks" paper.

$$\mathbf{x}_i' = lpha_{i,i} \mathbf{\Theta}_s \mathbf{x}_i + \sum_{j \in \mathcal{N}(i)} lpha_{i,j} \mathbf{\Theta}_t \mathbf{x}_j,$$

where the attention coefficients  $lpha_{i,j}$  are computed as

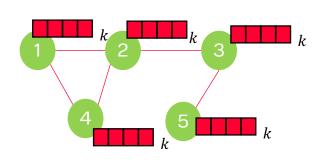
$$lpha_{i,j} = rac{\exp\left( ext{LeakyReLU}\left(\mathbf{a}_s^{ op}oldsymbol{\Theta}_s\mathbf{x}_i + \mathbf{a}_t^{ op}oldsymbol{\Theta}_t\mathbf{x}_j
ight)
ight)}{\sum_{k\in\mathcal{N}(i)\cup\{i\}}\exp\left( ext{LeakyReLU}\left(\mathbf{a}_s^{ op}oldsymbol{\Theta}_s\mathbf{x}_i + \mathbf{a}_t^{ op}oldsymbol{\Theta}_t\mathbf{x}_k
ight)
ight)}.$$

If the graph has multi-dimensional edge features  $\mathbf{e}_{i,j}$ , the attention coefficients  $\alpha_{i,j}$  are computed as

$$lpha_{i,j} = rac{\exp\left( \mathrm{LeakyReLU}\left(\mathbf{a}_s^{ op} oldsymbol{\Theta}_s \mathbf{x}_i + \mathbf{a}_t^{ op} oldsymbol{\Theta}_t \mathbf{x}_j + \mathbf{a}_e^{ op} oldsymbol{\Theta}_e \mathbf{e}_{i,j} 
ight) 
ight)}{\sum_{k \in \mathcal{N}(i) \cup \{i\}} \exp\left( \mathrm{LeakyReLU}\left(\mathbf{a}_s^{ op} oldsymbol{\Theta}_s \mathbf{x}_i + \mathbf{a}_t^{ op} oldsymbol{\Theta}_t \mathbf{x}_k + \mathbf{a}_e^{ op} oldsymbol{\Theta}_e \mathbf{e}_{i,k} 
ight) 
ight)}.$$

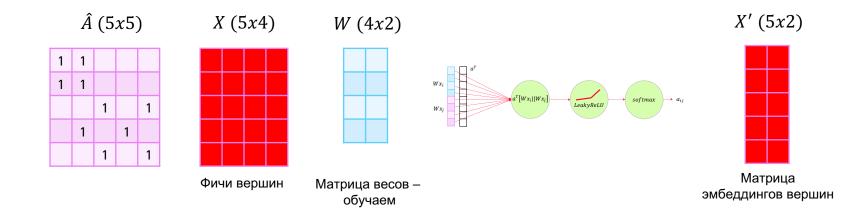
If the graph is not bipartite,  $\mathbf{\Theta}_s = \mathbf{\Theta}_t$ .

### Какая проблема с GATConv?

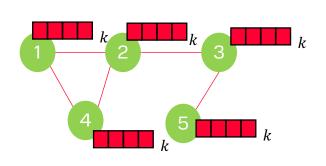


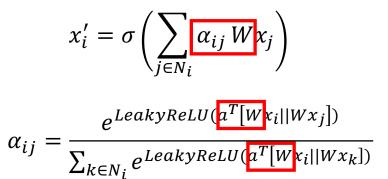
$$x_i' = \sigma\left(\sum_{j \in N_i} \alpha_{ij} \, W x_j\right)$$

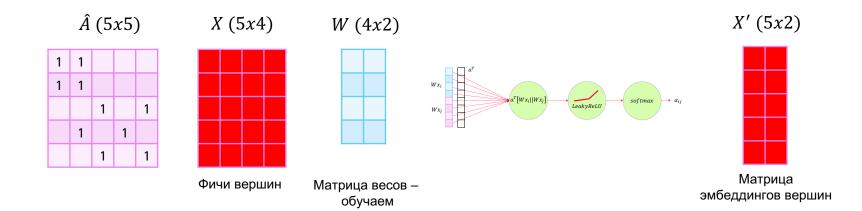
$$\alpha_{ij} = \frac{e^{LeakyReLU(a^T[Wx_i||Wx_j])}}{\sum_{k \in N_i} e^{LeakyReLU(a^T[Wx_i||Wx_k])}}$$

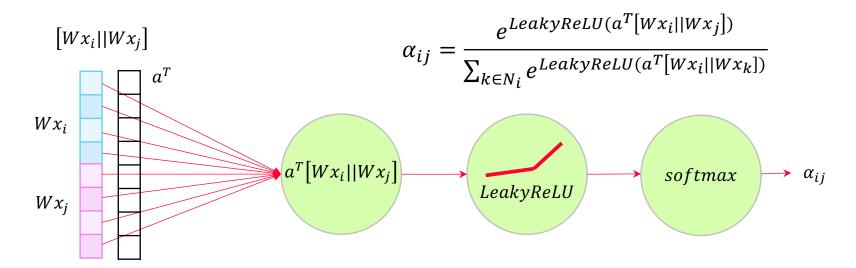


### Какая проблема с GATConv?



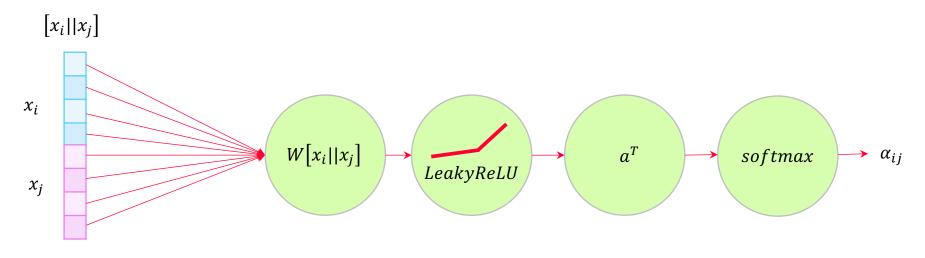






# M T

## **Graph Attention 2**

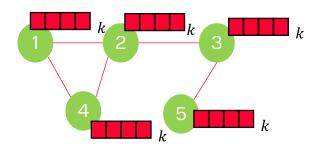


$$\alpha_{ij} = \frac{e^{a^T LeakyReLU(W[x_i||x_j])}}{\sum_{k \in N_i} e^{a^T LeakyReLU(W[x_i||x_k])}}$$

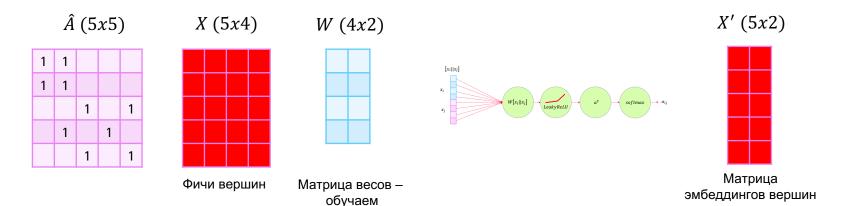
## Сравните

$$\alpha_{ij} = \frac{e^{LeakyReLU(a^T[Wx_i||Wx_j])}}{\sum_{k \in N_i} e^{LeakyReLU(a^T[Wx_i||Wx_k])}}$$
 vs

$$\alpha_{ij} = \frac{e^{a^T LeakyReLU(W[x_i||x_j])}}{\sum_{k \in N_i} e^{a^T LeakyReLU(W[x_i||x_k])}}$$

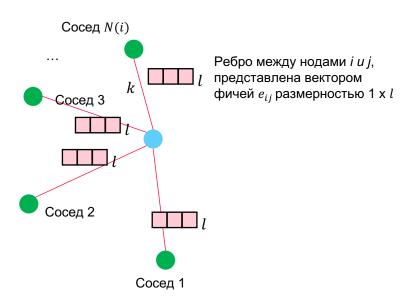


$$\alpha_{ij} = \frac{e^{LeakyReLU(a^T[Wx_i||Wx_j])}}{\sum_{k \in N_i} e^{LeakyReLU(a^T[Wx_i||Wx_k])}}$$



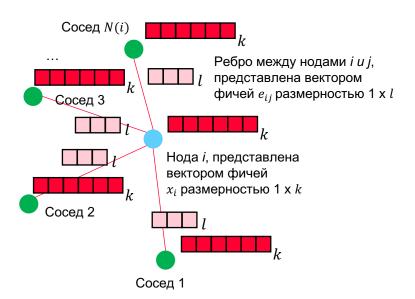


$$\mathbf{x}_i' = \mathbf{H}\mathbf{x}_i + \sum_{j \in [1, N(i)]} \mathbf{x}_j NN(e_{ij})$$



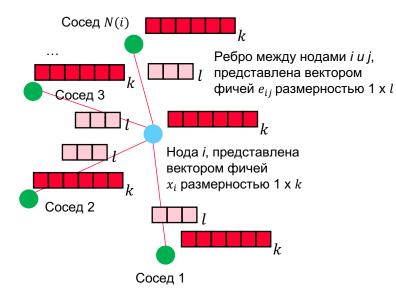


$$\mathbf{x}_i' = \mathbf{H}\mathbf{x}_i + \sum_{j \in [1, N(i)]} \mathbf{x}_j NN(e_{ij})$$

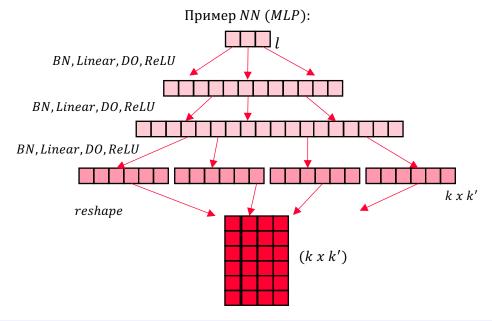




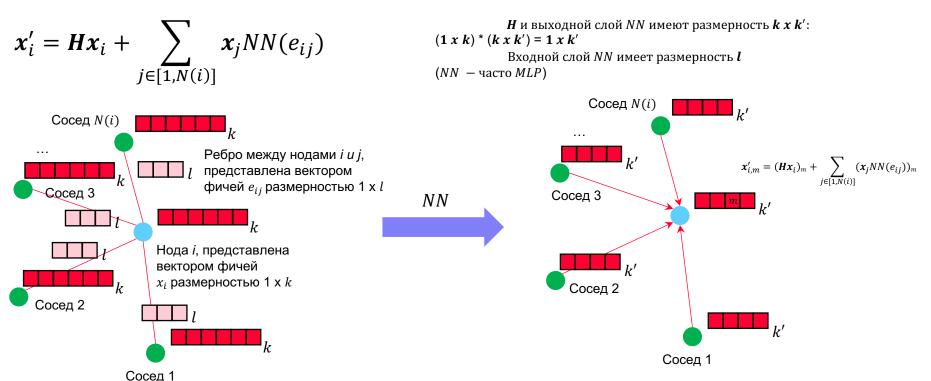
$$\mathbf{x}_i' = \mathbf{H}\mathbf{x}_i + \sum_{j \in [1, N(i)]} \mathbf{x}_j NN(e_{ij})$$



 $m{H}$  и выходной слой NN имеют размерность  $m{k}$  х  $m{k}'$ :  $(m{1}$  х  $m{k})$  \*  $(m{k}$  х  $m{k}')$  =  $m{1}$  х  $m{k}'$  Входной слой NN имеет размерность  $m{l}$  (NN — часто MLP)



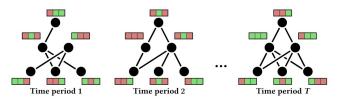




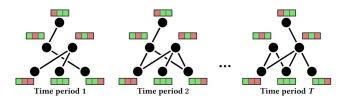
# Темпоральные графы



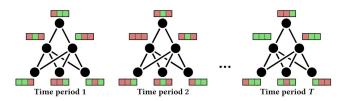
### Типы темпоральных графов



(a) Dynamic graph with temporal signal.

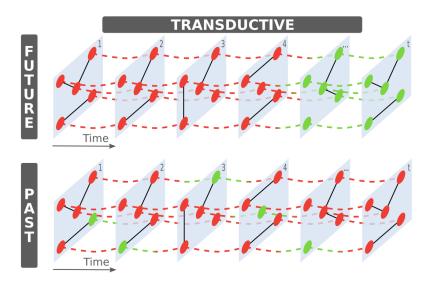


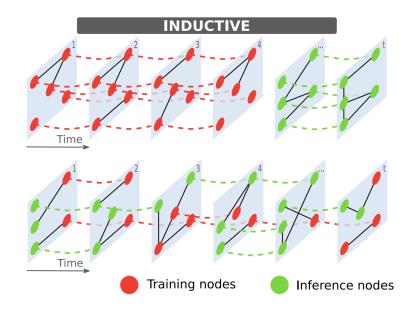
(b) Dynamic graph with static signal.



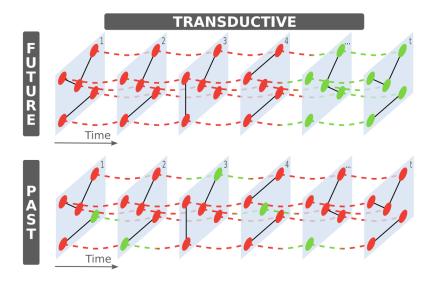
(c) Static graph with temporal signal.

(FT) предикт класса ноды в будущем, *предсказание траффика* 

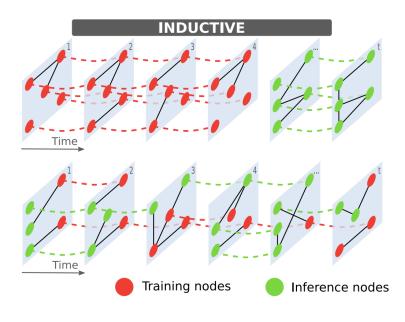




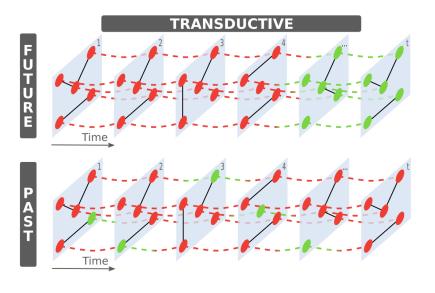
(FT) предикт класса ноды в будущем, *предсказание траффика* 



FI (future-inductive) – предикт класса **новой** ноды (не было в обучении) в будущем

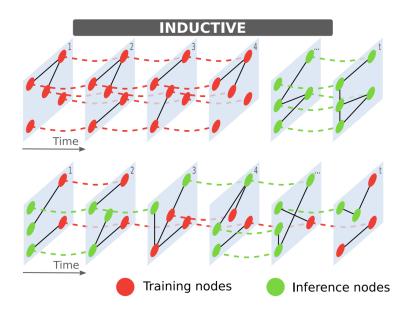


(FT) предикт класса ноды в будущем, *предсказание траффика* 

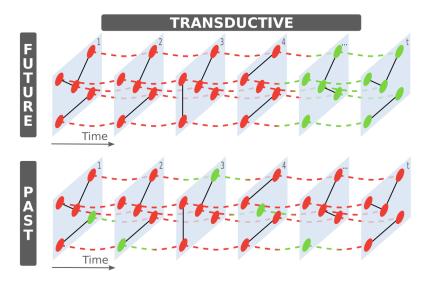


PT: Detecting critical stages during disease progression from gene expression profiles (Gao et al., 2022)

FI (future-inductive) – предикт класса **новой** ноды (не было в обучении) в будущем

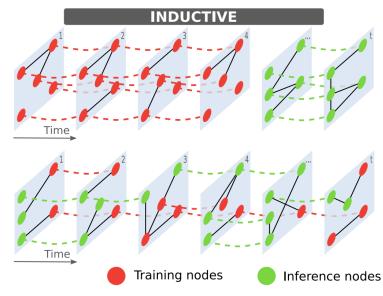


(FT) предикт класса ноды в будущем, *предсказание траффика* 

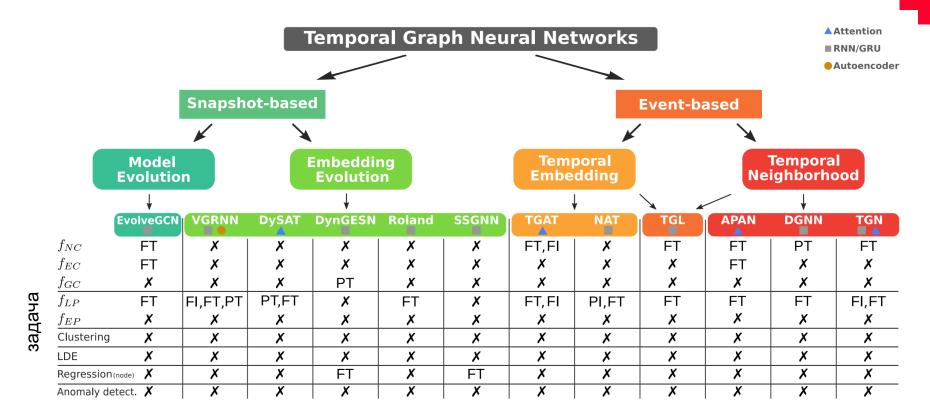


PT: Detecting critical stages during disease progression from gene expression profiles (Gao et al., 2022)

FI (future-inductive) – предикт класса **новой** ноды (не было в обучении) в будущем



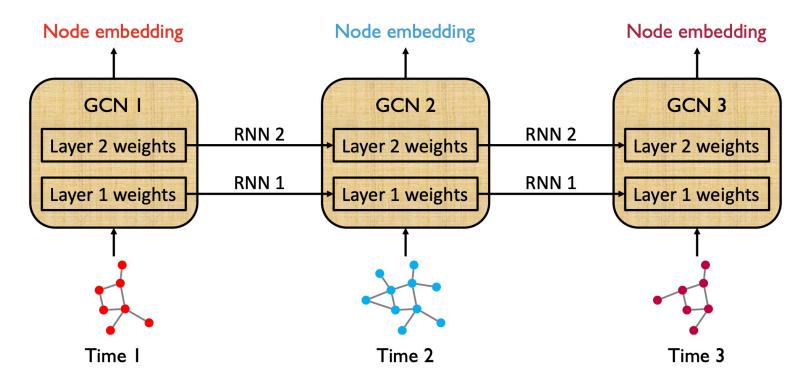
PI (past-inductive), предикт класса ноды, которая была недоступна (маскирована) в трейне или предикт ребра между нодами, которых не было в обучении



LDE == low-dimension embedding

#### и т С

#### EvolveGCN (2019)



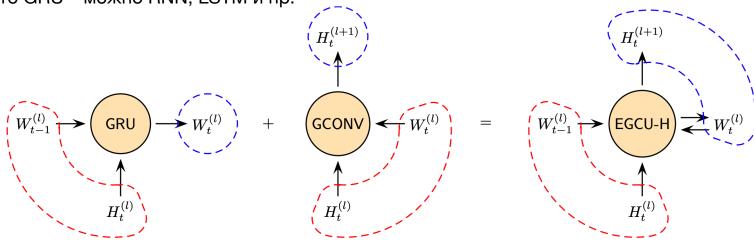
На вход RNN подавать не фичи / эмбеддинги вершин, а веса графовой свертки

#### EvolveGCN-H (2019)

$$H_t^{l+1} = \sigma(A_t H_t^l W_t^l)$$

$$W_t^l = GRU(H_t^l, W_{t-1}^l)$$

Вместо GRU - можно RNN, LSTM и пр.

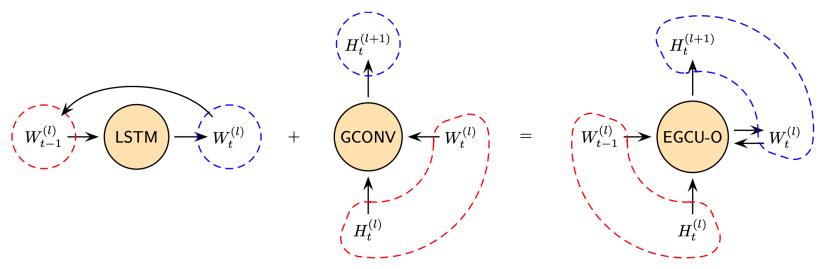


(a) EvolveGCN-H, where the GCN parameters are hidden states of a recurrent architecture that takes node embeddings as input.

#### EvolveGCN-O (2019)

$$H_t^{l+1} = \sigma(A_t H_t^l W_t^l)$$

$$W_t^l = LSTM(W_{t-1}^l)$$



(b) EvolveGCN-O, where the GCN parameters are input/outputs of a recurrent architecture.

#### В июне 2023 появился первый бенчмарк





https://tgb.complexdatalab.com/



https://torch-spatiotemporal.readthedocs.io/en/latest/
https://github.com/TorchSpatiotemporal/tsl

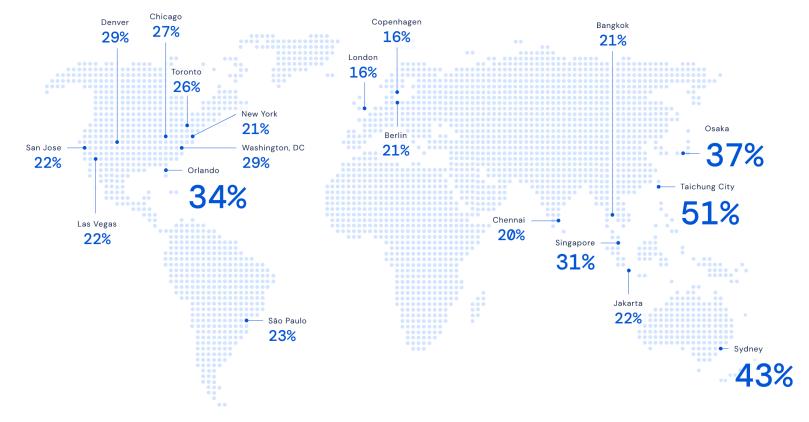


https://www.youtube.com/watch?v=rUR3-YIHFt0

# Задача ЕТА

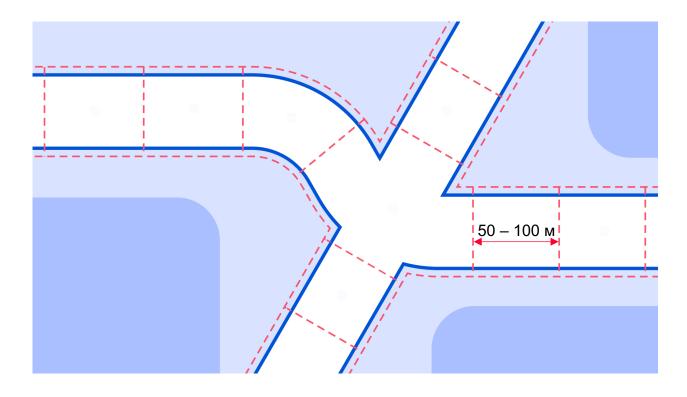


## Эффект от GNN в задаче ETA в Google Maps



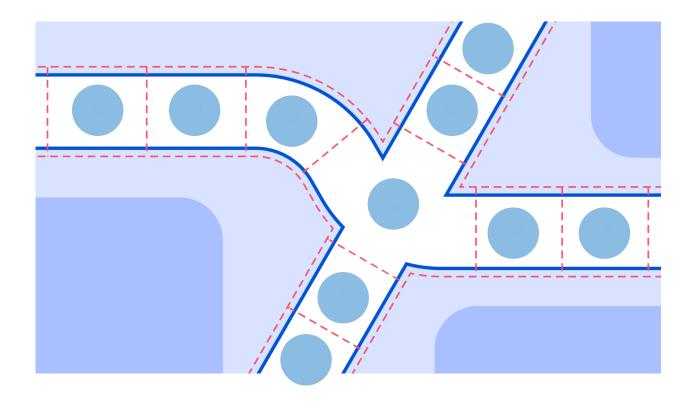
#### Дороги в графы





### Дороги в графы





$$\mathbf{e}'_{k} = \phi^{e} \left( \mathbf{e}_{k}, \mathbf{v}_{s_{k}}, \mathbf{v}_{t_{k}}, \mathbf{u} \right)$$

$$\mathbf{v}'_{i} = \phi^{v} \left( \bar{\mathbf{e}}'_{i}, \mathbf{v}_{i}, \mathbf{u} \right)$$

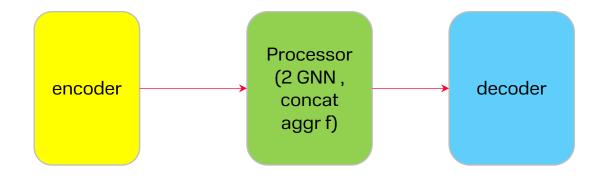
$$\mathbf{u}' = \phi^{u} \left( \bar{\mathbf{e}}', \bar{\mathbf{v}}', \mathbf{u} \right)$$

Текущие и исторические скорости, длина сегмента и приоритет (напр.: хайвэй), время и пр.

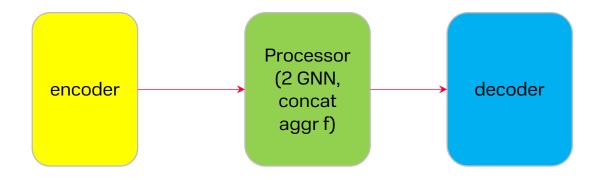
Время проезда по сегмента и скорости. Плюс обучаемые эмбеддинги сегмента / суперсегмента

#### м т С

#### Схема работы



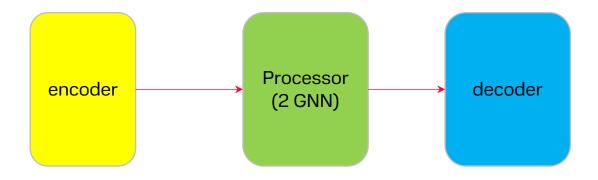
#### Схема работы



Не густо деталей. И где время?

#### Схема работы

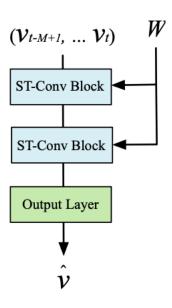




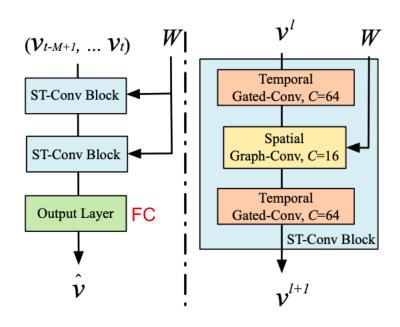
Не густо деталей. И где время?

5 GNN для пяти временных горизонтов

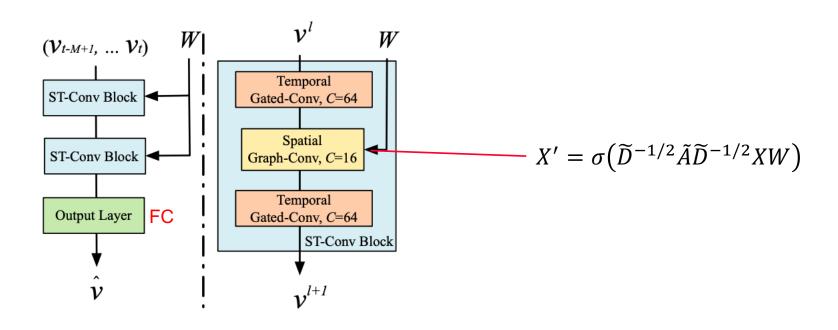




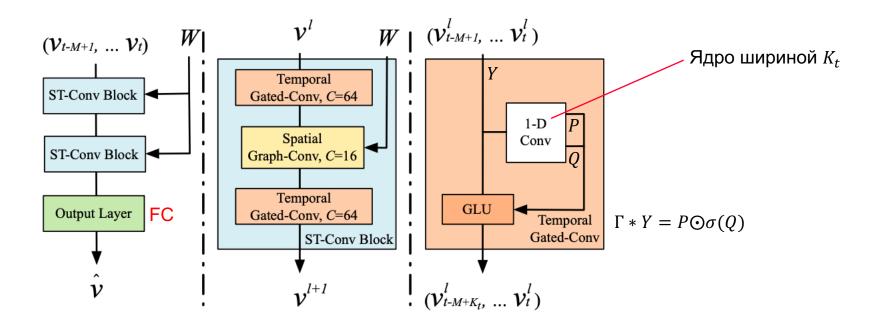












#### GLU (борьба с затуханием градиентов)

м т С

Градиент gate в LSTM

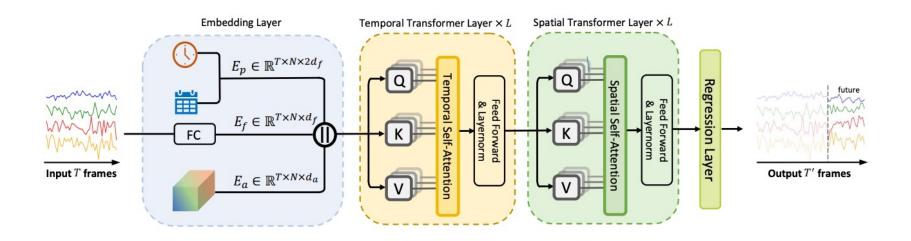
Градиент gate в GLU

$$\nabla (\tanh(X) \odot \sigma(X)) = \tanh'(X) \nabla X \odot \sigma(X) + \sigma'(X) \nabla X \odot \tanh(X)$$

$$\nabla (X \odot \sigma(X)) = \nabla X \odot \sigma(X) + X \odot \sigma'(X) \nabla X$$

#### **STAEformer**





<sup>\*</sup> Notably, we also apply layer normalization, residual connection and multi-head mechanism